

Entwicklung eines Monitoring Tools zur Beurteilung von Muskelultraschallbildern

Quynh Anh Nguyen, Heyi Wang, Dilan Mohammadi, Lea Grün
Technische Universität Darmstadt

Zusammenfassung—Diese Arbeit vergleicht 3 Machine Learning Modelle zur Klassifikation von Muskelatrophie, anhand von Ultraschallbildern. Dabei werden radiomische Merkmale verwendet zum Training von einem Künstlichen Neuronalen Netzwerk (ANN), Support Vector Machine (SVM) und Logistische Regression (LoRe). Die Datenbasis umfasst 258 Ultraschallbilder, aufgeteilt in Normalbefunde und krankhafte Befunde. Die Ergebnisse zeigen, dass das ANN mit einem F1-Score von 0.9 am besten abschneidet, gefolgt von SVM und LoRe. Darüber hinaus wurde eine Analyse der Feature Importance durchgeführt, wobei 13 Merkmale identifiziert wurden, die für die Diagnose besonders relevant sind. Diese Arbeit bietet Einblicke in die potenziellen Einsatzmöglichkeiten von maschinellem Lernen in der medizinischen Bildgebung, insbesondere zur Verbesserung der Diagnose von Muskelpathologien.

Keywords – Muskelatrophie, ANN, SVM, LoRe, Heckmatt, Ultraschall

I. EINLEITUNG

Muskelabbau, auch Muskelatrophie genannt, ist eine Folgeerscheinung einer hohen Immobilisation, die besonders Patienten auf der Intensivstation betreffen [1, 2]. Der Verlust von Muskeldicke korreliert mit der Aufenthaltsdauer. Muskelatrophie tritt bei bis zu 90% der Patienten nach Intensivpflege, die eine Dauer von 28 Tagen übersteigt, auf [3, 4]. Zur Bewertung der physiologischen Muskelmorphologie können verschiedene Bildgebungstechniken eingesetzt werden. Als praktisches Messinstrument zur Dokumentation des Verlaufs des Muskelabbaus wird der Ultraschall herangezogen. Dieser wird auch als Teil der täglichen Routine auf einer Intensivstation eingesetzt [2]. Die Beurteilung der aufgenommenen Ultraschallbilder der Muskeln wird bisher im Klinikum Darmstadt noch manuell durchgeführt. Neben dem hohen zeitlichen Aufwand hat diese Methode auch einen subjektiven Einflussfaktor. Die Auswertung durch künstliche Intelligenz könnte die Genauigkeit der Diagnosen verbessern und die Zeiteffizienz in den Prozessen erhöhen. KI-Systeme ermüden nicht und arbeiten durchgehend auf gleichbleibend hohem Niveau, was die Zuverlässigkeit der Diagnosen erheblich steigert. Dadurch wird die Abhängigkeit von der Erfahrung und dem momentanen Zustand des Diagnosepersonals vermieden [5].

II. HINTERGRUND

Ultraschallbilder basieren auf Schallwellen und deren Reflexionen. Reflexionen treten auf, beim Auftreffen des Ultraschallstrahlstrahls auf Gewebe, welches unterschiedliche Eigenschaften aufweist. Trifft die Schallwelle zum Beispiel auf Muskelgewebe findet eine Teilreflexion statt. Starke Reflexionen treten beim Übergang von Luft zu Knochen auf, da

sie einen großen Unterschied in der akustischen Impedanz aufweisen. Solche starken Reflexionen führen zu hellen Bildanteilen. Strukturen unterhalb einer solch starken Reflexion können nicht dargestellt werden.[6]. Heckmatt und Dubowitz et al. [7] entwickelten eine Bewertungsskala, die Ultraschallaufnahmen von Muskeln in vier verschiedene Grade einteilt (Abbildung 1). Bei dieser Einteilung wird die Darstellung des Knochenechos, die Anzahl der zurückkehrenden Echos des Muskels pro Quadratfläche [6], bekannt als Echogenität, die Unterscheidbarkeit zum umliegenden Gewebe sowie die dargestellte Echotextur berücksichtigt [7, 8]. Unter Grad 1 wird der Normalzustand verstanden. Grad 2 steht für eine leicht erhöhte Echointensität des Muskels und einem uneinträchtigen Knochenecho. Bei Grad 3 sind eine erhöhte muskuläre Echointensität und ein abgeschwächtes Knochenecho zu sehen. Bei Grad 4, und damit dem schwerwiegendsten Grad, weisen die Bilder kein sichtbares Knochenecho mehr auf und zeigen eine stark erhöhte Echointensität des Muskels [7, 8]. Grund für den Schwund der Muskulatur ist die durch die Immobilisation verursachte Flüssigkeitsretention [2].




Abbildung 1: Visuelle Bewertungsskala der Ultraschallaufnahmen nach Heckmatt [9]

Neue Entwicklungen im Bereich künstliche Intelligenz sowie Machine Learning haben viel zur computerunterstützten Krankheitsdiagnostik beigetragen, besonders bei der Klassifizierung und Quantifizierung von Ultraschallbildern [10, 11]. Cunningham et al. [12, 13] ist es gelungen, ein großes Convolutional Neural Network (CNN) Modell aus 8 Convolutional-Schichten zu entwickeln, um den Muskelzustand anhand von über 300.000 Ultraschallaufnahmen zu beurteilen. Das Modell

kann die Bilder zusätzlich segmentieren und augmentieren und erreicht eine Genauigkeit von über 50%. Burlina et al. [14] verfolgt einen anderen Ansatz zur Diagnose von Muskelentzündungen, indem er AlexNet mit 5 Convolutional-Schichten und 2 Dense-Schichten einsetzt. Durch die Methode kann eine Sensitivität von über 70% gewährleistet werden. Trotz ihrer häufigen Anwendung neigen CNN-Modelle dazu Muster auswendig zu lernen. Das führt dazu, dass eine große Datenmenge für den Erfolg entscheidend ist. Ihre Robustheit bei kleinen Datensätzen ist jedoch noch nicht ausreichend untersucht. Merkmale aus Ultraschallbildern zu extrahieren und diese zur Klassifikation zu nutzen ist eine Methode, die sich besser für Modelle wie SVM eignet, so wie von Yeh et al. implementiert [15]. Zur Auswertung von Leberzirrhose berechnet der Autor Merkmale anhand der Wavelet-Transformation und der Grauwertmatrix und erzielt mit Hilfe der SVM eine Genauigkeit von bis zu 90%. Attia et al. [16] verfolgt denselben Ansatz, setzt jedoch ein ANN zur Klassifikation von Nierenultraschallbildern ein. Dabei kann eine korrekte Klassifikationsrate von bis zu 97% erzielt werden. Die Anwendung im Bereich der Muskeluntersuchungen ist aktuell noch eingeschränkt und bedarf weiterer Forschung.

Bezüglich des Feature Engineering bietet die radiomische Analyse ein leistungsstarkes Werkzeug zur Extraktion klinisch relevanter Informationen aus radiologischen Bildgebungen, unter anderem Ultraschallbildern [17]. Radiomics kann verwendet werden, um Gewebe- und Läsionseigenschaften wie Form und Heterogenität zu erfassen und bisher unbekannte Marker und Muster zu entdecken [18]. Radiomische Merkmale lassen sich grob in folgende Kategorien unterteilen: statistische Merkmale, einschließlich histogrammbasierter und texturbasierter Merkmale; modellbasierte Merkmale; transformierte Merkmale; und formbasierte Merkmale [19]. Michael et al. [20] untersucht Texturmerkmale wie das Intensitätshistogramm, die Grauwert-Korrelationsmatrix (GLCM) und die Run-Length-Matrix (RLM) im Hinblick auf die Zusammensetzung der Skelettmuskulatur und zeigt nützliche Anwendungen zur Unterscheidung von Muskelgewebe über verschiedene Geschlechter, Altersgruppen und klinische Kohorten hinweg. In Kombination mit Machine Learning Modellen wie ANN und SVM kann Fernandez et al. [21] bei der Beurteilung von Pneumonie anhand von Röntgenaufnahmen eine hohe Genauigkeit von über 97% erzielen. Weitere Anwendungen sind unter anderem die Diagnose von Zervixkarzinomen [22], die Charakterisierung von fokalen Leberläsionen [23], die Erkennung abnormer Gehirn-MRT-Befunde [24].

Ziel dieser Arbeit ist es, radiomische Merkmale aus Muskelultraschallbildern zu extrahieren und verschiedene Modelle zu trainieren, um anschließend eine Klassifikation zwischen gesund und krank zu ermöglichen. Hierzu wird die Einteilung der Bilder nach Heckmatt und Dubowitz verwendet. In diesem Projekt wird lediglich zwischen Normalbefund (Grad 1), und krankhaft (Grad 2 bis Grad 4) unterschieden. Zur Klassifizierung der beiden Fälle werden drei weniger verbreitete Modelle eingesetzt: Logistische Regression, Support Vector Machine und ein Künstliches Neuronales Netzwerk. Die Ergebnisse

dieser Modelle werden am Ende verglichen.

III. MATERIAL UND METHODIK

Abbildung 2 zeigt schematisch den zugrundeliegenden Ablauf dieses Projekts.




Abbildung 2: Ablaufmodell

A. Ultraschallsonde und Datenaufnahme

Für die Datenaufnahme wurden die folgenden vier Muskeln auf beiden Seiten geschallt: M. biceps brachii, M. quadriceps, M. tibialis anterior und der M. Brachioradialis. Dabei wurde darauf geachtet, dass die Schallsonde im rechten Winkel zum Körper war. Die Aufnahme der Muskelquerschnitte wurde in zwei verschiedenen Modi durchgeführt, MSK und SMP, wobei die Dynamik und Verstärkung auf 50 Prozent festgelegt wurden. Für die Tiefe hingegen wurde kein fester Wert bestimmt, sondern abhängig vom Patienten gewählt.

Für die Aufnahme der Ultraschallbilder wurde ein kabelloser Hochfrequenz-Linearscanner (L15 HD3) der Firma Clarius verwendet. Dieser kann Aufnahmen bis zu einer Tiefe von 7 cm machen und ist besonders geeignet für die Aufnahme von Nerven, MSK, Brust, Small Parts, Superficial und Thyroid. Der L15 HD3 weist einen Frequenzbereich von 5-15 MHz auf [25]. Zur Darstellung der Bilder und zum Einstellen verschiedener Parameter wurde die Clarius App verwendet. Zur Kontaktherstellung zwischen der Ultraschallsonde und der Haut, wurde das SONOSID Ultraschallgel der Firma ASID BONZ eingesetzt, welches für Ultraschall-Anwendungen in der diagnostischen und therapeutischen Medizin vorgesehen ist [26].

B. Datensatz

Der Datensatz besteht insgesamt aus 258 B-Mode Ultraschallbildern, darunter 129 Normalbefunde und 129 Ultraschallbilder mit krankhafter Veränderung. Ein Teil der B-Mode Normalbefunde sowie die krankhaften Befunde wurden von der Klinik für Neurologie und Neurointensivmedizin in Darmstadt zur Verfügung gestellt. Abbildung 3 zeigt den Datensatz, aufgeteilt in die zwei verwendeten Modi MSK und SMP. Abbildung 5 stellt den verwendeten Datensatz nach der Skalierung von Heckmatt dar.

Aufgrund der begrenzten Datenmenge wurden die Gesamtdaten nur in Trainings- und Testdatensätze aufgeteilt, ein Validierungsdatensatz wurde hierbei vernachlässigt. Das Verhältnis




Abbildung 3: Anzahl der Bilder pro Modi: Insgesamt gibt es 155 Bilder im MSK-Modus und 103 Bilder im SMP-Modus




Abbildung 4: Anzahl der Bilder pro Körperregion Arm oder Bein: Insgesamt gibt es 167 Bilder vom Bein und 91 Bilder vom Arm




Abbildung 5: Einteilung des Datensatzes nach Heckmatt und Dubowitz

zwischen Trainings- und Testdatensatz beträgt 80:20. Die Ultraschallaufnahmen wurden sorgfältig sortiert, um sicherzustellen, dass keine doppelten Bilder vorhanden sind.

C. Segmentierung

Vor dem Feature Engineering wurde bei jedem Bild ein Ausschnitt vom Knochen und Muskel segmentiert. Für die Knochenausschnitte wurde eine Bildgröße von 256x256 Pixel festgelegt. Die Muskelausschnitte hingegen wurden mit

128x128 Pixel kleiner gewählt, damit nur die relevanten Muskelstrukturen in dem Bildausschnitt enthalten sind. Abbildung 6 zeigt beispielhaft das Vorgehen bei der Segmentierung der beiden Bildausschnitte.




Abbildung 6: Segmentierung der Bilder aus dem Datensatz: Knochenausschnitte mit Größe 256x256 Pixel, Muskelausschnitte mit Größe 128x128 Pixel

D. Feature Engineering

Die bestimmten Bildausschnitte wurden zuerst bezüglich ihrer Grauwerte untersucht. Dafür wurden die statistischen Größen Mittelwert, Median, Standardabweichung, Skewness und Kurtosis berechnet. Die verwendeten Formeln können dem Anhang C entnommen werden.

Zusätzlich zu den ermittelten statistischen Größen zur Analyse der Grauwerte, wurde auch eine Texturanalyse durchgeführt. Dabei wurden Features nach Galloway und nach Haralick bestimmt. Die Berechnung der Features nach Galloway basiert auf einer Lauflängenmatrix (RLM). Die Matrix weist eine Dimension $N \times M$ auf, hierbei repräsentiert N die Anzahl der Grauwerte des Bildes und M die Länge der Graustufenverläufe. Unter Graustufenverlauf wird eine Anzahl an aufeinanderfolgenden Bildpunkten mit dem gleichen Grauwert verstanden. Somit gibt ein Element der Matrix an, wie oft ein bestimmter Grauwert, aufeinanderfolgend in einer bestimmten Richtung vorgekommen ist. Dabei können die Durchläufe für verschiedene Winkel durchgeführt werden. In dieser Arbeit wird die Berechnung der RLM für die folgenden Winkel bestimmt 0° , 45° , 90° und 135° .

Aus der berechneten Matrix können dann die Merkmale SRE (Short Runs Emphasis), LRE (Long Runs Emphasis), GLNU (Gray Level Nonuniformity), RLNU (Run Length Nonuniformity) und RP (Run Percentage) bestimmt werden. Die genaue mathematische Berechnung kann dem Anhang B entnommen werden. Bei der Berechnung des Merkmals SRE werden die kurzen Verläufe hervorgehoben, wohingegen die langen Läufe bei der Merkmalsberechnung LRE hervorgehoben werden. Das Merkmal GLNU misst die Ungleichmäßigkeit der Grauwertstufen des Bildausschnittes. Die Ungleichmäßigkeit der Lauflängen wird durch RLNU ausgedrückt. Das fünfte Merkmal RP setzt die vorhandene Anzahl an Läufen ins Verhältnis mit der möglichen Gesamtanzahl an Läufen, die eine Länge von eins aufweisen. [27] Nach der Berechnung

der Features für jeden Winkel, werden die Ergebnisse für die einzelnen Features aufsummiert und normiert. Diese fünf Features SRE, LRE, GLNU, RLNU und RP wurden für die weiteren Schritte verwendet.

Die Berechnung der Features nach Haralick beruht auf einer GLCM Matrix. Die Dimension dieser Matrix entspricht der Anzahl der Grauwerte im Bild, beziehungsweise wie in dieser Arbeit, der Anzahl der Grauwerte im jeweiligen Bildausschnitt [28]. Dabei wird untersucht, wie oft ein bestimmter Grauwert neben einem anderen bestimmten Grauwert vorkommt. Diese Werte werden dann in die Matrix eingetragen. Diese Berechnung kann für mehrere Winkel durchgeführt werden da, die Kombinationen der Grauwert-Nachbarn auch diagonal oder um 90° gedreht vorkommen können [29]. Diese Arbeit beinhaltet nur die Grauwertpaare der nächsten horizontalen Nachbarn. Dafür wurde eine Distanz von 1 und ein Winkel von 0° zur Berechnung verwendet.

Nach der Bestimmung der Matrix wurden die nachfolgend beschriebenen sechs Features zur Texturbeschreibung berechnet. Der Kontrast ist ein Maß für die Schwankung der Grauwerte im Bild. Höhere Merkmalswerte entsprechen einer höheren Variation im Bild. Das Merkmal Korrelation ist ein Maß für die linearen Abhängigkeiten der Grauwerte im Bild. Enthält ein Bild zum Beispiel Rauschen, so sind die Werte für das Korrelationsmerkmal niedriger, da Rauschen ein eher unkorreliertes Merkmal darstellt. Ausgeprägte Grautonübergänge werden durch das Merkmal Homogenität ausgedrückt. Weißt das Bild größere Übergänge in den Grauwerten auf, wird das Merkmal einen höheren Wert aufweisen [29]. Die Entropie ist ein Merkmal zur Bestimmung der Unordnung und Zufälligkeit der Pixelwerte. Die Homogenität des Bildes wird hier durch das Merkmal Energie ausgedrückt. Zuletzt wurde die Unähnlichkeit (Dissimilarity) bestimmt, welche die Unterschiede zwischen den Intensitäten der Pixel quantifiziert [30]. Insgesamt wurden 32 Features für das Training der Modelle genutzt.

E. Modelle

Für die Klassifikation der einzelnen Segmente wurden ein ANN, eine SVM und ein LoRe verwendet. Vor dem Trainieren wurden alle berechneten Merkmale für bessere Konvergenz, Stabilität und ein schnelleres Training auf einen Bereich zwischen [0, 1] normalisiert [31, 32].

Das ANN beginnt mit einer Eingangsschicht der Dimension 32, gefolgt von einem Hidden Layer mit 16 Neuronen. Diese Schicht verfügt über eine ReLU-Aktivierungsfunktion und einer Lernrate von 0.001. In der Ausgangsschicht wurde die Sigmoid Aktivierungsfunktion angewendet. Beim Training aller drei Modelle wird eine Kreuzvalidierung durchgeführt, um das Fehlen eines Validierungsdatensatzes zu kompensieren und Overfitting zu vermeiden. Zudem wird eine Hyperparameteroptimierung eingesetzt, um die bestmögliche Architektur zu finden. Detaillierte Graphiken und genauere Informationen zum Training befinden sich in Anhang F.

Die Ausgaben der SVM und von LoRe sind bereits binäre Klassifikationen von '1' (Krank) oder '0' (Gesund). Die

Ausgabe des ANNs erstreckt sich im Gegensatz dazu über das kontinuierliche Intervall zwischen 0 und 1. Diesbezüglich wird ein sinnvoller Schwellwert eingesetzt, um die Ausgabe in eine binäre Form umzuwandeln. Übersteigt der Wert den Schwellwert, so wird er mit '1' (Krank) und sonst mit '0' (Gesund) versehen.

IV. ERGEBNIS

Zur Auswertung unserer Ergebnisse werden die Metriken F1-Score, Accuracy, Precision, Recall und die True Negative Rate (TNR) betrachtet. Diese Metriken der verwendeten 3 Modelle können dem Balkendiagramm in Abbildung 7 entnommen werden. Es zeigt sich, dass mit dem ANN der beste F1-Score von 0,9 erreicht wurde. Die SVM erreichte mit einem F1-Score von 0,88 den zweiten Platz, während das LoRe mit einem F1-Score von 0,83 die schlechteste Leistung zeigte.




Abbildung 7: Ergebnismetriken der 3 Modelle

Zusätzlich werden ROC-Kurven der 3 Modelle in der Abbildung 8 dargestellt. Aufgrund des begrenzten Testdatensatzes erscheinen die Kurven treppenförmig und nicht glatt. Dennoch ergibt die ROC-Kurve ähnliche Ergebnisse, wobei ANN mit einem AUC-Wert von 0,97 am besten abschneidet.




Abbildung 8: ROC-Kurve der 3 Modelle

Um die Relevanz der einzelnen Features und deren Beitrag zur Klassifizierung zu ermitteln, wird eine Feature-Importance-Analyse für das Modell der logistischen Regression durchgeführt. Dabei werden die Merkmale systematisch

entfernt (Feature Ablation) und das Modell wird erneut trainiert. Anhand des F1-Scores durch Kreuzvalidierung kann die beste Feature-Kombination identifiziert werden, die den höchsten Score ergibt. Die Abbildung 9 zeigt das Ergebnis der Analyse der Feature importance für das ausgewählte Modell logistische Regression. Dabei wird auf der y-Achse die Metrik F1 aufgetragen und die x-Achse gibt die Anzahl der gewählten Features an. Das Ergebnis zeigt, dass mit der




Abbildung 9: Darstellung des F1 Score in Abhängigkeit der Anzahl der gewählten Features für das Modell logistische Regression

Kombination aus 13 bestimmten Features der F1-Score auf fast 0.9 verbessert werden kann. Darüber hinaus ist zu erkennen, dass bereits mit 3 bestimmten Features ein F1-Score von über 0.825 erreicht werden kann. Zu den drei Features gehören, der Kontrast des Knochens, die Unähnlichkeit des Muskels und die Standardabweichung des Muskels. Um einen ersten Eindruck zu bekommen, wie sich die drei Merkmalswerte auf die Daten verteilen werden diese nachfolgend in Abbildung 10, 11 und 12 als Boxplots dargestellt.




Abbildung 10: Darstellung des Features Knochen Kontrast (normiert) in einem Boxplot in Abhängigkeit der Grade. Dabei wurde Grad 3 und 4 zusammengefasst.




Abbildung 11: Darstellung des Features Muskel Standardabweichung (normiert) in einem Boxplot in Abhängigkeit der Grade. Dabei wurde Grad 3 und 4 zusammengefasst.




Abbildung 12: Darstellung des Features Muskel Dissimilarity (normiert) in einem Boxplot in Abhängigkeit der Grade. Dabei wurde Grad 3 und 4 zusammengefasst.

Dabei wurden die normierten Merkmalswerte in die verschiedenen Grade unterteilt. Grad 3 und 4 wurden jeweils zusammengefasst, da die Anzahl der Ultraschallbilder mit Grad 4 begrenzt ist. Die Grafiken wurden anhand des Trainingsdatensatzes erstellt.

Nach erneutem Trainieren des Modells mit den 13 Features weisen alle Metriken einen Wert von 0.88 auf. Die Ergebnismetriken, mit den zuvor verwendeten 32 Features, weisen nur kleinere Werte zwischen 0.81 und 0.85 auf. Die detaillierte Liste der 13 Features kann dem Anhang E entnommen werden.




Abbildung 13: Darstellung der Ergebnismetriken vor und nach der Feature importance für das Modell logistische Regression

V. DISKUSSION UND AUSBLICK

Die Ergebnisse in Abschnitt IV verdeutlichen, dass nicht-traditionelle Methoden wie ANN, SVM und LoRe bei ausreichender Merkmalserfassung in der Bildklassifikation ebenfalls leistungsfähig sein können. Unter diesen Ansätzen zeigt das ANN die beste Performance, während LoRe die schlechtesten Ergebnisse liefert. Alle drei Modelle zeigen eine relativ ausgewogene True Positive Rate (TPR) und True Negative Rate (TNR) auf, was darauf hindeutet, dass sie sowohl kranke als auch gesunde Befunde gleich gut klassifizieren können.

Eine detaillierte Analyse zeigt, dass die falsch klassifizierten Daten hauptsächlich den Bildern mit Grad 1 und Grad 2 zuzuordnen sind. Diese Klassen weisen in der Praxis geringe Unterschiede auf, oft nur von Experten erkennbar. Werden Ultraschallbilder mit Grad 1 und Grad 4 verglichen so weisen diese erkennbare Unterschiede auf, wodurch eine gute Klassifizierung mit den verwendeten Modellen möglich war. Darüber hinaus haben die Modelle Schwierigkeiten bei der Klassifikation verrauschter Bilder. Eine größere Datenmenge könnte die Fehlklassifikationsrate möglicherweise reduzieren. Durch Data Augmentation könnten zusätzlich künstliche Daten generiert werden, womit eine vergrößerte Datenmenge erzielt werden kann. Somit wäre eine Klassifikation in 4 Grade und die Anwendung von CNNs eventuell möglich. Auch eine Aussage über die Eignung der Ultraschallmodi und Körperteile, welche für die Ultraschallaufnahmen gewählt wurden, könnte so möglich werden.

Dass das LoRe am schwächsten abschneidet stimmt mit den Resultaten von Khemphila [33] und Imkhiran [34] überein. Diese vergleichen verschiedene Klassifikationen, inklusive LoRe, miteinander. LoRe zeigt als einfaches Modell Defizite beim Umgang mit komplexen und hochdimensionalen Daten. Auch in Bezug auf seine Empfindlichkeit gegenüber Ausreißern sind Einschränkungen vorhanden. Trotzdem können alle seine Metriken nach einer Feature-Importance-Analyse im Durchschnitt um etwa 5% verbessert werden. Dies bedeutet, wenn mehr Daten und mehr Merkmale mit einer detaillierten Untersuchung der Merkmalswichtigkeit zur Verfügung stehen, könnten alle Modelle weiter verfeinert werden und bessere

Ergebnisse erzielen.

Bei Betrachtung des Merkmals Kontrast, bei den Knochenausschnitten, sind deutliche Unterschiede zwischen dem Normalbefund (Grad 1) und den krankhaften Befunden (Grad 2-4) zu erkennen. Dabei weist das Merkmal bei Grad 1 meist deutlich höhere Werte auf als bei Grad 2, Grad 3 oder Grad 4. Ähnliches Verhalten weist das Merkmal Standardabweichung bei den Muskelausschnitten auf. Auch hier nimmt das Merkmal für den Grad 1 höhere Werte an, im Vergleich zu den anderen Graden. Beim dritten dargestellten Merkmal lässt sich keine klare Abgrenzung zwischen den Merkmalswerten erkennen. Hierbei weist das Merkmal Unähnlichkeit der Muskelausschnitte bei den krankhaften Befunden teilweise einen leicht höheren Wert auf, jedoch haben die Werte auch große Überschneidungen.

In zukünftigen Arbeiten könnte es lohnenswert sein, die Segmentierung der relevanten Knochen- und Muskelausschnitte für eine bessere Generalisierungsfähigkeit mithilfe von Machine Learning Modellen zu automatisieren [35]. Darüber hinaus sollten die Auswirkungen verschiedener Filter auf die Bilder untersucht werden, um aussagekräftigere Merkmale zu extrahieren und somit die Robustheit der Methoden zu verbessern. Ein weiteres Potenzial besteht in der Transformation der Bilder in den Frequenzbereich, um die Textur der Bilder noch genauer zu analysieren [20].

VI. ZUSAMMENFASSUNG

In dieser Arbeit wird ein System zur Klassifikation von Muskelultraschallbildern mit Hilfe von radiomischen Merkmalen entwickelt, um zwischen gesunden und kranken Muskelzuständen zu unterscheiden. Drei Klassifikationsmodelle wurden trainiert und evaluiert, dabei das ANN die besten Ergebnisse erzielt, gefolgt von SVM, und LoRe am schlechtesten abschneidet.

Die Grenzen dieser Arbeit waren durch einen beschränkten Datensatz gegeben. Ungewiss ist das Verhalten der Modelle bei einem größeren Datensatz. Zukünftige Arbeiten könnten darauf abzielen, die vorgeschlagenen Modelle und ihre Klassifikationsalgorithmen weiterzuentwickeln. Darüber hinaus könnte eine automatisierte Segmentierung von Knochen- und Muskelausschnitten, mithilfe von maschinellen Lernmodellen, zur Vereinfachung des Prozessablaufs in Betracht gezogen werden. Eine Anwendung verschiedener Bildfilter sowie die Untersuchung der Ultraschallbilder in unterschiedlichen Domänen wäre von Interesse, um die Modelle weiter zu optimieren. Zudem könnten mehr radiomische Merkmale im Zusammenhang mit der Feature-Selektion verwendet werden, was jedoch einen höheren Ressourcenbedarf erfordert.

LITERATUR

- [1] T. Müller-Wolff R. Larsen T. Fink. *Larsens Anästhesie und Intensivmedizin für die Fachpflege*. 10. Aufl. Springer, 2021. ISBN: 978-3-662-63126-3. DOI: <https://doi.org/10.1007/978-3-662-63127-0>.
- [2] W. Gruther u.a. "Muscle Wasting in Intensive Care Patients: Ultrasound Observation of the M. Quadriceps Femoris Muscle Layer". In: *Journal of Rehabilitation Medicine* 40 (2008), S. 185–189. ISSN: 1650-1977. DOI: 10.2340/16501977-0139.
- [3] Heidrun Fink u.a. "Systemic inflammatory response syndrome increases immobility-induced neuromuscular weakness". In: *Critical Care Medicine* 36.3 (2008), S. 910–916. DOI: 10.1097/CCM.0B013E3181659669.
- [4] Arabella Fischer u.a. "Zusammenhang zwischen Muskeldicke und Flüssigkeitsbilanz bei herzthoraxchirurgischen Intensivpatienten nach Elektrostimulation (Catastim2)". In: *Aktuelle Ernährungsmedizin* 40 (Mai 2015). DOI: 10.1055/s-0035-1550172.
- [5] Stefan Cristian Dinescu u.a. "Applications of artificial intelligence in musculoskeletal ultrasound: narrative review". In: *Frontiers in Medicine* 10 (2023). ISSN: 2296-858X. DOI: 10.3389/fmed.2023.1286085. URL: <https://www.frontiersin.org/journals/medicine/articles/10.3389/fmed.2023.1286085>.
- [6] Mehdi Sehri. "Qualitativer und Quantitativer Ultraschall der Muskulatur - ein Parameter zur Verlaufsbeurteilung bei der Muskeldystrophie Duchenne". Jan. 2022. URL: <http://nbn-resolving.de/urn:nbn:de:bvb:19-293771>.
- [7] J.Z. Heckmatt, S. Leeman und V. Dubowitz. "Ultrasound imaging in the diagnosis of muscle disease". In: *The Journal of Pediatrics* 101.5 (1982), S. 656–660. ISSN: 0022-3476. DOI: [https://doi.org/10.1016/S0022-3476\(82\)80286-2](https://doi.org/10.1016/S0022-3476(82)80286-2).
- [8] Heidrun H. Krämer, Catherine Bulinski und Kathrin Habig. "Muskelsonografie". In: *Klinische Neurophysiologie* 50.1 (2019), S. 23–27. DOI: 10.1055/a-0810-4646.
- [9] Jemima Albayda und Nens van Alfen. "Diagnostic Value of Muscle Ultrasound for Myopathies and Myositis". In: *Current Rheumatology Reports* 22.11 (2020). ISSN: 1523-3774, 1534-6307. DOI: 10.1007/s11926-020-00947-y. URL: <https://link.springer.com/10.1007/s11926-020-00947-y>.
- [10] D. Shen, G. Wu und H. I. Suk. "Deep Learning in Medical Image Analysis". In: *Annual Review of Biomedical Engineering* 19 (2017), S. 221–248. DOI: 10.1146/annurev-bioeng-071516-044442.
- [11] Rebeca Tenajas u.a. "Recent Advances in Artificial Intelligence-Assisted Ultrasound Scanning". In: *Applied Sciences* 13.6 (2023). ISSN: 2076-3417. DOI: 10.3390/app13063693. URL: <https://www.mdpi.com/2076-3417/13/6/3693>.
- [12] Ryan J. Cunningham und Ian D. Lorum. "Estimation of absolute states of human skeletal muscle via standard B-mode ultrasound imaging and deep convolutional neural networks". In: *Journal of The Royal Society Interface* 17.162 (2020), S. 20190715. DOI: 10.1098/rsif.2019.0715. URL: <https://royalsocietypublishing.org/doi/abs/10.1098/rsif.2019.0715>.
- [13] Ryan J. Cunningham, Peter J. Harding und Ian D. Lorum. *The application of deep convolutional neural networks to ultrasound for modelling of dynamic states within human skeletal muscle*. 2017. DOI: <https://doi.org/10.48550/arXiv.1706.09450>. URL: <https://arxiv.org/abs/1706.09450>.
- [14] Philippe Burlina u.a. "Automated diagnosis of myositis from muscle ultrasound: Exploring the use of machine learning and deep learning methods". In: *PLOS ONE* 12.8 (Aug. 2017), S. 1–15. DOI: 10.1371/journal.pone.0184059. URL: <https://doi.org/10.1371/journal.pone.0184059>.
- [15] Wen-Chun Yeh, Sheng-Wen Huang und Pai-Chi Li. "Liver fibrosis grade classification with B-mode ultrasound". In: *Ultrasound in Medicine Biology* 29.9 (2003), S. 1229–1235. ISSN: 0301-5629. DOI: [https://doi.org/10.1016/S0301-5629\(03\)01010-X](https://doi.org/10.1016/S0301-5629(03)01010-X). URL: <https://www.sciencedirect.com/science/article/pii/S030156290301010X>.
- [16] Mariam Attia u.a. "Classification of Ultrasound Kidney Images using PCA and Neural Networks". In: *IJACSA International Journal of Advanced Computer Science and Applications*, 6 (Apr. 2015), S. 53–57. DOI: 10.14569/IJACSA.2015.060407.
- [17] Michal R. Tomaszewski und Robert J. Gillies. "The Biological Meaning of Radiomic Features". In: *Radiology* 298.3 (2021). PMID: 33399513, S. 505–516. DOI: 10.1148/radiol.2021202553. URL: <https://doi.org/10.1148/radiol.2021202553>.
- [18] M. E. Mayerhoefer u.a. "Introduction to Radiomics". In: *Journal of Nuclear Medicine* 61.4 (2020), S. 488–495. DOI: 10.2967/jnumed.118.222893.
- [19] Andrzej Materka. "Texture analysis methodologies for magnetic resonance imaging". In: *Dialogues in Clinical Neuroscience* 6.2 (2004), S. 243–250.
- [20] Michael T. Paris und Marina Mourtzakis. "Muscle Composition Analysis of Ultrasound Images: A Narrative Review of Texture Analysis". In: *Ultrasound in Medicine Biology* 47.4 (2021), S. 880–895. ISSN: 0301-5629. DOI: <https://doi.org/10.1016/j.ultrasmedbio.2020.12.012>. URL: <https://www.sciencedirect.com/science/article/pii/S030156292030569X>.
- [21] Carlos Fernandez-Grandon u.a. "SVM and ANN classification using GLCM and HOG features for COVID-19 and Pneumonia detection from Chest X-rays". In: *2021 Third South American Colloquium on Visible Light Communications (SACVLC)*. 2021, S. 01–06. DOI: 10.2340/16501977-0139.
- [22] Muhammad Thohir u.a. "Classification of Colposcopy Data Using GLCM-SVM on Cervical Cancer". In: *2020 International Conference on Artificial Intelligence*

- in *Information and Communication (ICAIC)*. 2020, S. 373–378. DOI: 10.1109/ICAIC48513.2020.9065027.
- [23] Simona Turco u. a. “Interpretable Machine Learning for Characterization of Focal Liver Lesions by Contrast-Enhanced Ultrasound”. In: *IEEE Transactions on Ultrasonics, Ferroelectrics, and Frequency Control* 69.5 (2022), S. 1670–1681. DOI: 10.1109/TUFFC.2022.3161719.
- [24] C.Thirumarai Selvi, R. S. Sankarasubramanian und S. Karthikeyani. “Multikernel Support Vector Machine with GLCM For Truthful Brain Signal Classification of Magnetic Resonance Imaging”. In: *2022 8th International Conference on Advanced Computing and Communication Systems (ICACCS)*. Bd. 1. 2022, S. 246–251. DOI: 10.1109/ICACCS54159.2022.9785363.
- [25] Clarius. *Hochfrequenz-Linearscanner*. Zugriff am: 1. Juli 2024. URL: <https://clarius.com/de/scanners/115/>.
- [26] ASID BONZ GmbH. *SONOSID® Ultraschall-Gel*. Zugriff am: 31. Juli 2024. URL: <https://www.asid-bonz.de/produkte/detailseite/sonosidr-ultraschall-gel/>.
- [27] Mary M. Galloway. “Texture analysis using gray level run lengths”. In: *Computer Graphics and Image Processing* 4.2 (1975), S. 172–179. ISSN: 0146-664X. DOI: [https://doi.org/10.1016/S0146-664X\(75\)80008-6](https://doi.org/10.1016/S0146-664X(75)80008-6). URL: <https://www.sciencedirect.com/science/article/pii/S0146664X75800086>.
- [28] Filippo Molinari u. a. “Advances in Quantitative Muscle Ultrasonography Using Texture Analysis of Ultrasound Images”. In: *Ultrasound in Medicine Biology* 41.9 (2015), S. 2520–2532. ISSN: 0301-5629. DOI: <https://doi.org/10.1016/j.ultrasmedbio.2015.04.021>. URL: <https://www.sciencedirect.com/science/article/pii/S0301562915003208>.
- [29] Robert M. Haralick, K. Shanmugam und Its’Hak Dinstein. “Textural Features for Image Classification”. In: *IEEE Transactions on Systems, Man, and Cybernetics SMC-3.6* (1973), S. 610–621. DOI: 10.1109/TSMC.1973.4309314.
- [30] G. Eberlein B. M. Jebin M. A. Rejula. “Neonatal Seizure detection using GLCM feature extraction AlexNet classification”. In: *Multimedia Tools and Applications* (2024). ISSN: 1573-7721. DOI: 10.1007/s11042-024-18779-8.
- [31] J. Sola und Joaquin Sevilla. “Importance of input data normalization for the application of neural networks to complex industrial problems”. In: *Nuclear Science, IEEE Transactions on* 44 (Juli 1997), S. 1464–1468. DOI: 10.1109/23.589532.
- [32] Sejal Jaiswal. *What is Normalization in Machine Learning? A Comprehensive Guide to Data Rescaling*. Zugriffen: 27. Juli 2024. URL: <https://www.datacamp.com/tutorial/normalization-in-machine-learning>.
- [33] Anchana Khemphila und Veera Boonjing. “Comparing performances of logistic regression, decision trees, and neural networks for classifying heart disease patients”. In: *2010 International Conference on Computer Information Systems and Industrial Management Applications (CISIM)*. 2010, S. 193–198. DOI: 10.1109/CISIM.2010.5643666.
- [34] Imran Kurt, Mevlut Ture und A. Turhan Kurum. “Comparing performances of logistic regression, classification and regression tree, and neural networks for predicting coronary artery disease”. In: *Expert Systems with Applications* 34.1 (2008), S. 366–374. ISSN: 0957-4174. DOI: <https://doi.org/10.1016/j.eswa.2006.09.004>. URL: <https://www.sciencedirect.com/science/article/pii/S0957417406002855>.
- [35] Neil J. Cronin, Taija Finni und Olivier Seynnes. “Using deep learning to generate synthetic B-mode musculoskeletal ultrasound images”. In: *Computer Methods and Programs in Biomedicine* 196 (2020), S. 105583. ISSN: 0169-2607. DOI: <https://doi.org/10.1016/j.cmpb.2020.105583>.
- [36] *Was ist die Konfusionsmatrix? — Data Basecamp*. Zugriff am: 14. Juli 2024. URL: <https://databasecamp.de/ki/konfusionsmatrix>.
- [37] A Tharwat. “Parameter investigation of support vector machine classifier with kernel functions”. In: *Knowledge and Information Systems* 61 (2019), S. 1274–1280. ISSN: 0219-3116. DOI: <https://doi.org/10.1007/s10115-019-01335-4>.
- [38] Gareth James u. a. *An Introduction to Statistical Learning: With Applications in R*. Springer Nature, 2021, S. 380–383.
- [39] *RBF SVM parameters — scikit-learn 1.5.1 documentation*. Zugriff am: 27. Juli 2024. URL: https://scikit-learn.org/stable/auto_examples/svm/plot_rbf_parameters.html.
- [40] *LogisticRegression — scikit-learn 1.5.1 documentation*. Zugriff am: 28. Juli 2024. URL: https://scikit-learn.org/stable/modules/generated/sklearn.linear_model.LogisticRegression.html.
- [41] Anuja Nagpal. *L1 and L2 Regularization Methods, Explained*. Zugriff am: 28. Juli 2024. URL: <https://builtin.com/data-science/l2-regularization>.

ANHANG A

Aus einer GLCM können folgende Features berechnet werden [28] [30]:

$$Dissimilarity = \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} P(i, j) |i - j| \quad (1)$$

$$Correlation = \frac{\sum_{i=0}^{N-1} \sum_{j=0}^{N-1} (i, j) P(i, j) - \mu_x \mu_y}{\sigma_x \sigma_y} \quad (2)$$

$$Contrast = \sum_{n=0}^{N-1} n^2 \left\{ \sum_{i=0}^N \sum_{j=0}^N P(i, j) \right\} \quad (3)$$

$$Entropy = - \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} P(i, j) \log P(i, j) \quad (4)$$

$$Energy = \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} P(i, j)^2 \quad (5)$$

$$Homogeneity = \sum_{i=0}^{N-1} \sum_{j=0}^{N-1} \frac{1}{1 + (i - j)^2} * P(i, j) \quad (6)$$

Die Variablen μ_x und μ_y sowie σ_x und σ_y stellen die Standardabweichungen und Mittelwerte von P_x und P_y dar. Diese stehen für die partielle Wahrscheinlichkeitsdichtefunktion. [28]

ANHANG B

Aus der RLM können viele Features berechnet werden [28]. Im Rahmen dieses Projekts werden folgende Features benutzt:

$$SRE = \frac{\sum_{i=1}^{N_g} \sum_{j=1}^{N_r} \frac{R(i, j)}{j^2}}{\sum_{i=1}^{N_g} \sum_{j=1}^{N_r} R(i, j)} \quad (7)$$

$$LRE = \frac{\sum_{i=1}^{N_g} \sum_{j=1}^{N_r} j^2 R(i, j)}{\sum_{i=1}^{N_g} \sum_{j=1}^{N_r} R(i, j)} \quad (8)$$

$$GLNU = \frac{\sum_{i=1}^{N_g} (\sum_{j=1}^{N_r} R(i, j))^2}{\sum_{i=1}^{N_g} \sum_{j=1}^{N_r} R(i, j)} \quad (9)$$

$$RLNU = \frac{\sum_{i=1}^{N_r} (\sum_{j=1}^{N_g} R(i, j))^2}{\sum_{i=1}^{N_g} \sum_{j=1}^{N_r} R(i, j)} \quad (10)$$

$$RP = \frac{\sum_{i=1}^{N_g} \sum_{j=1}^{N_r} R(i, j)}{N_g \bar{M}_r} \quad (11)$$

Die Anzahl der Grauwerte wird durch N_g ausgedrückt und die Variable N_r stellt die Anzahl an Läufen dar. $R(i, j)$ gibt die Pixel in der RLM wieder, wobei i der Intensität entspricht und j der Lauflänge. [28]

ANHANG C

Aus einem Histogramm können folgenden Features berechnet werden [28]:

$$Mean = \sum_{x=1}^M \sum_{y=1}^N \frac{I(x, y)}{M * N} \quad (12)$$

$$STD(\sigma) = \sqrt{\frac{\sum_{x=1}^M \sum_{y=1}^N \{I(x, y) - m\}^2}{M * N}} \quad (13)$$

$$Skewness = \frac{1}{M * N} \frac{\sum_{x=1}^M \sum_{y=1}^N \{I(x, y) - m\}^3}{\sigma^3} \quad (14)$$

$$Kurtosis = \frac{1}{M * N} \frac{\sum_{x=1}^M \sum_{y=1}^N \{I(x, y) - m\}^4}{\sigma^4} \quad (15)$$

Unter der Variable $I(x, y)$ versteht man die eingangs ausgewählte Muskelregion von Interesse (ROI).

ANHANG D

Nachfolgend sind die Berechnungen der Metriken gezeigt, welche für den Ergebnisteil bestimmt wurden. [36]

$$Precision = \frac{TP}{TP + FP} \quad (16)$$

$$Recall = \frac{TP}{TP + FN} \quad (17)$$

$$TNR = \frac{TN}{TN + FP} \quad (18)$$

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (19)$$

$$F1 = \frac{2 * Precision * Recall}{Precision + Recall} \quad (20)$$

Dabei sagt True Positive (TP) aus wie viele Bilder als krank klassifiziert werden und es auch wirklich sind. False Positive (FP) repräsentiert die Bilder die als krank klassifiziert werden, es aber in Wirklichkeit nicht sind. False Negative (FN) gibt an wie viele Bilder als gesund klassifiziert werden, aber tatsächlich krank sind. Die letzte Einteilung True Negative (TN) gibt die als krank erkannten Bilder an, die tatsächlich zu den kranken Aufnahmen gehören. [36]

ANHANG E

Nach Feature Importance Analyse vom LoRe Modell zeigt die Feature-Kombination in Tabelle I das beste Ergebnis. Hier ist zu sehen, dass Knochenmerkmale im Vergleich zu Muskelmerkmalen einen größeren Beitrag bei der Klassifikation leisten.

	Knochen	Muskel
Histogramm	- Standardabweichung - Kurtosis	- Mittelwert - Standardabweichung
GLCM	- Kontrast - Homogenität - Energie - Korrelation	- Dissimilarität - Homogenität
RLM	- LRE - GLNU - RLNU	

Tabelle I: Die Besten 13 Merkmale nach Feature Importance Analyse

ANHANG F

In Abbildung 14 ist die Architektur des verwendeten ANN-Modells beschrieben. Der Flowchart der drei verwendeten Methoden einschließlich Optimierungsverfahren ist in Abbildung 15 zu finden. Nach Abbildung 15 folgen nun detaillierte Informationen zu den Parametern der SVM und des LoRes, die im Rahmen dieser Arbeit verwendet wurde:

SVM:

- C: Strafparameter. Der C-Parameter definiert den erlaubten Fehlerbereich im Training. Ein kleinerer C-Wert führt zu einer größeren Margin, was jedoch zu Fehlklassifikationen führen kann. Ein größerer C-Wert führt zu einer kleineren Margin und versucht, alle Beispiele korrekt zu klassifizieren [37].
- Kernel: Ein Kernel ist eine Funktion, die die Ähnlichkeit zwischen zwei Beobachtungen quantifiziert [38]. Dabei wurde 'poly' ausgewählt.
- Gamma: Der Gamma-Parameter definiert, wie weit der Einfluss eines einzelnen Trainingsbeispiels reicht [39]. Dabei wurde 'scale' ausgewählt.

Logistische Regression:

- C: Der Parameter C entspricht dem Kehrwert der Regularisierungsstärke. Dabei spezifizieren kleinere Werte eine stärkere Regularisierung [40].
- Solver: Besteht ein Optimierungsproblem, so ist der Parameter solver zu wählen. Dabei wurde 'saga' gewählt. Diese Einstellung wird bei größeren Datensätzen verwendet [40].
- Penalty: Der Parameter Penalty kann ein Overfitting durch Hinzufügen eines Strafterms verhindern [40, 41].




Abbildung 15: Gesamter Ablauf des Trainings mit Hyperparameter-optimierung und Kreuzvalidierung




Abbildung 14: Die Architektur des verwendeten ANN Modells